

學士學位 卒業論文
指導教授 문정환 교수님
<표지>

압력센서 데이터를 기반으로 인공지능을 이용한 저가형 COM 예측 모델

成均館大學校
바이오메카트로닉스 學科
조용승 김현석 정재훈

學士學位 卒業論文
指導教授 문정환 교수님
<내표지>

압력센서 데이터를 기반으로 인공지능을 이용한 저가형 COM 예측 모델

Research on a low-cost COM prediction model using
A.I based on pressure sensor data

成均館大學校
바이오메카트로닉스 學科
조용승 김현석 정재훈

學士學位 卒業論文
指導教授 문정환 교수님
<심사청구서>

<인정서>

압력센서 데이터를 기반으로 인공지능을
이용한 저가형 COM 예측 모델

Research on a low-cost COM prediction model using
A.I based on pressure sensor data

이 論文을 工學 學士學位 卒業論文으로 提出합니다.

2023年 11月 24日

成均館大學校
바이오메카트로닉스 學科

조용승 김현석 정재훈

이 論文을 조용승, 김현석, 정재훈의 工學
學士學位 論文으로 認定함.

2023年 11月 24日

審査委員長 (김형건 교수님) ㉠

審査委員 (문정환 교수님) ㉠

목차

제1장

- 1. 서론
- 1.1 연구배경
- 1.2 연구목적
- 1.3 압력 센서 데이터를 이용한 COM 추정 선행연구
- 1.4 사용한 인공지능 모델
- 1.4.1 RF
- 1.4.2 CNN
- 1.4.3 Bi-LSTM

제2장

- 2. 연구 방법
- 2.1 실험 데이터
- 2.2 데이터 전처리
- 2.3 인공지능 모델
- 2.3.1 모델 설계
- 2.3.2 베이지안 최적화와 그리드서치
- 2.3.3 정규화
- 2.3.4 RF
- 2.3.5 CNN
- 2.3.6 Bi-LSTM
- 2.4 예측 모델 평가지표

제3장

- 3. 연구결과
- 3.1 인공지능 모델 학습 결과
- 3.1.1 모델 성능평가
- 3.1.2 EO와 EC 결과
- 3.1.3 예측 결과 Plot & Graph
- 3.2 모델 검증
- 3.2.1 ANOVA & Post Hoc Test
- 3.2.2 결과

제4장

- 4. 논의
- 4.1 인공지능 모델 예측 결과 비교 및 원인 분석
- 4.2 한계점

제5장

- 5. 결론

표목차

- 표 1 Bayesian optimization range
- 표 2 Bayesian optimization value
- 표 3 3가지 모델의 각 축에 대한 성능 평가 결과

표 4 3가지 모델의 각 축에 대한 표준편차의 백분율

표 5 EO, EC에서 3가지 모델에 대한 각 축의 성능 평가 결과

표 6 ANOVA와 Post Hoc Test 결과

그림목차

그림 1 SOT 장비를 이용한 어지럼증 검사

그림 2 압력센서 발판

그림 3 Vicon 프로그램 센서

그림 4 Calibration용 막대

그림 5 35개 마커 마킹 전과 후

그림 6 마커 연결 작업 전과 후

그림 7 노이즈 제거 작업

그림 8 Pipeline 작업

그림 9 Gait model

그림 10 모델 설계 순서도

그림 11 RF architecture

그림 12 CNN architecture

그림 13 Bi-LSTM architecture

그림 14 EO, EC, Total rRMSE 결과 그래프

그림 15 COM 예측 결과 plot

논문요약

압력센서 데이터를 기반으로 인공지능을 이용한 저가형 COM 예측 모델

Center of Mass(COM)는 물체의 질량이 모여 있는 지점으로, 물체의 움직임과 안정성을 이해하는 핵심적인 개념이다. COM의 정확한 분석은 운동 분석, 안정성 평가, 동작 기술의 최적화에 기여하는 등 다양한 분야에서 활용된다. 특히 인간의 보행 분석이나 자세 제어와 같은 바이오메카닉스 학문 분야에서 COM의 추정 은 매우 중요하다. COM을 추정하는 방법에는 여러 가지가 있지만 가장 정확도가 높고 많이 사용되는 것은 동작분석기를 통한 COM 획득이다. 하지만 동작분석기 같은 경우 3000만원 상당의 고비용이 요구되기 때문에 상용화되기 어렵다. 본 연구는 이를 해결하기 위해 동작분석기로 COM을 획득하는 대신 저가의 장비로 압력 데이터를 획득하고 인공신경망 모델을 이용하여 압력 데이터 기반으로 COM을 예측하려고 한다. 기존의 COP를 기반으로 Filtering method를 통해 COM을 획득하는 방법은 x축과 y축에 대한 값을 획득하지만 본 연구는 x축, y축 그리고 z축에 대한 COM을 예측한다. 실험을 통해 인공지능 모델에서 사용할 데이터를 획득하고 전처리를 진행하였다. 인공신경망 모델은 Random Forest(RF), Convolution Neural Network(CNN), Bidirectional Long Short-Term Memory(Bi-LSTM)을 사용하였고 전처리 된 데이터를 MinMaxScaler를 이용하여 정규화 하여 각 모델로 예측을 하고 비교하였다. 평가지표는 r(Correlation Coefficient), RMSE, rRMSE를 사용하였고 이를 통해 모델의 성능을 평가 및 비교하였다.

주제어 : 압력, COM, RF, CNN, Bi-LSTM

제1장 서론

1. 서론


1.1 연구배경

COM(Center Of Mass)이란 질량 중심으로 물체의 질량이 균형을 이루는 지점이다.¹⁾ COM이 어디에 위치하는지는 물체의 특성을 결정하는 중요한 요소 중 하나인데, 특히 운동과 안정성은 물체의 움직임을 이해하고 예측하는 데에 핵심적인 요소로 작용한다. 예를 들어, 안정성은 건축물, 차량, 로봇 등의 설계에서 고려해야 할 중요한 측면 중 하나이다. COM에 대한 연구는 안전성과 관련된 물리학적 부분뿐만 아니라, 바이오메카닉스의 분야에서도 활용되고 있는데 인간의 운동과 안정성에 대한 중요한 지표로 작용한다. 바이오메카닉스는 인간의 생체 역학을 공학적 원리와 융합하여 이해하고 최적화하는 분야로, 인간의 운동 및 안정성을 이해하는 핵심적인 요소 중 하나로 COM이 부각되고 있다.²⁾ COM은 인간의 운동에 대해 그 위치와 움직임을 추적하여 보행, 뛰기, 앉기 등 다양한 운동 패턴을 분석한다. 이를 통해 인간 운동의 생체 역학적 특성을 파악하고, 개별 운동 패턴에 대한 최적화 전략을 찾을 수 있다.³⁾ 또한 COM의 추정은 운동 장애의 진단과 치료에도 중요한 역

1) A. L. Betker, T. "Estimation of 2-D Center of Mass Movement During Trunk Flexion-Extension Movements Using Body Accelerations." IEEE Transactions on Neural Systems and Rehabilitation Engineering Volume 17, no. 6 (2009): 553 - 559.

2) LATTANZI, Emanuele, et al. Standing balance assessment by measurement of body center of gravity using smartphones. IEEE Access, 2020, 8: 96438-96448.

할을 한다. 특히 균형에 문제가 있는 환자들에게 COM 분석을 통하여 개별 맞춤형 치료 전략의 개발에 기여할 수 있다. 이와 관련하여 의료 장비 및 보조기구 개발에도 영향을 미쳐 기존보다 안정적이고 효과적이며 환자들에게 유리한 자원이 제공될 수 있다. 이와 관련하여, 사람의 어지럼증을 일으키는 원인을 진단하는 SOT(Sensory Organization Test)에서는 COM을 추정하는 것이 굉장히 중요한 작업이다. 이때 SOT는 6가지 테스트를 사용하여 각 경우의 수마다 감각 입력을 조작하여 진행되는데 신체의 전방/후방 무게중심 위치를 평가한다. 6가지 테스트의 경우 그림 1과 같다. SOT는 노인의 균형 관련 진정 장애, 다발성 경화증 및 파킨슨병 환자의 초기 균형 능력을 평가하는데 널리 사용되고 있다.⁴⁾



<그림 1> SOT 장비를 이용한 어지럼증 검사

3) Yi-Chung Pai, "Center of Mass Velocity-Position Predictions for Balance Control." Journal of Biomechanics Volume 30, no. Issue 4 (1997): 347 - 354.

4) A. Choi, E. Park, T. H. Kim, G. J. Im and J. H. Mun. "A Novel Optimization-Based Convolution Neural Network to Estimate the Contribution of Sensory Inputs to Postural Stability During Quiet Standing." IEEE Journal of Biomedical and Health Informatics Volume 26, no. 9 (2022): 4414 - 4425.

이때 어지럼증을 호소하는 환자를 SOT를 통해 어지럼증을 유발하는 감각 기관을 추정할 수 있다. 그러나 움직이는 영상, 서라운드 시스템, 플랫폼 구동 장치와 같은 복잡하고 큰 장치들이 필요하고 무엇보다 초기 비용이 상대적으로 매우 높다. 또한 기존 COM을 분석하는 동작분석기의 경우 3000만원 이상의 고가의 장비가 필요하기 때문에 COM을 추정하는 작업은 비용적인 문제가 상당하다. 이러한 문제들로 경제적인 문제를 해결하며 정확한 COM을 추정할 수 있는 연구들이 진행 중이다.

1.2 연구목적

본 연구의 목적은 압력 센서 데이터를 기반으로 한 COM 추정이다. COM 추정에 대한 효과적인 모델링을 수행하는 것이 주된 목적이다. 이에 대한 선행연구를 참고하여 Real-Trem 프로그램을 활용하여 센서마다 압력을 측정하고 이를 기록 및 저장한다. 그리고 motion capture system을 이용하여 타겟으로 활용할 COM 데이터를 기록 및 저장한다. 획득한 데이터를 Bi-LSTM, CNN, RF 세 가지 인공지능 모델을 이용하여 COM을 예측하려고 한다.

센서마다 측정된 압력은 압전소자의 전압으로 변환되어 기록되며 이를 활용하여 COM을 추정한다. 그리고 Bi-LSTM, CNN, RF 세 가지 모델은 COM 추정을 위한 각기 다른 방식의 모델을 사용한다. Bi-LSTM은 장기 의존성을 고려하여 시계열 데이터를 처리하고, CNN은 지역적인 특징을 추출하여 공간적인 패턴을 인식하며, RF는 의사 결정 트리의 앙상블을 통해 다양한 패턴을 학습한다. 사용한 세 가지 모델의 학습 및 평가를 통해 각 모델이 COM을 얼마나 효과적으로 추정하는지 비교한다. 모델 간 성능의 차이와 특징을 분석하여, 어떤 모델이 어떤 특징이 있는지 파악한다. 또한 복잡한 장치 및 높은 가격 등의 문제를 해결하기 위해 300만원 정도 가격의 압력발판 센서만을 이용하기 때문에 더욱 간단한 장치와 우수한 가격 경쟁

력이라는 이점을 갖는다. 이 연구를 통해 실제 인공지능 모델들의 정확도를 판단하여 그 효용성을 알아보고자 한다.

1.3 압력 센서 데이터를 이용한 COM추정 선행연구

많은 선행연구들에서 압력센서 데이터를 사용하여 COM을 추정하는 다양한 방법론과 모델링 기법이 소개되었다. 압력 센서 데이터에서 발밑의 압력 영역을 분석하여 COM을 추정하며 그 사이의 관계를 파악하고 압력 영역과 COM위치 사이의 상관 관계를 모델링하는 영역 분석, 압력 센서 데이터의 프로파일을 생성하고 그 프로파일은 시간에 따른 압력 분포의 변화를 나타내며 COM의 움직임과 관련된 정보를 제공하여 추정하는 프로파일 분석, 압력 센서 데이터를 수집하고 이를 기계학습 모델과 머신 러닝 모델에 입력하여 회귀 모델, 신경망, 랜덤 포레스트 혹은 Bi-LSTM과 같은 모델을 사용하여 추정하는 방법 등이 있다.⁵⁾ 선행 연구들을 바탕으로 바닥과 인체의 상호 작용을 기록하는 압력 센서 데이터는 COM의 추정에 깊은 연관이 있음을 알 수 있다. 이를 통해 본 논문은 머신러닝 모델을 통해 COM을 추정하고자 한다.

1.4 사용한 인공지능 모델

1.4.1 RF

Random Forest(RF)는 의사 결정 트리(Decision Tree)를 기반으로 한 앙상블 학

5) Sonobe, Motomichi, and Yoshio Inoue. 2023. "Center of Mass Estimation Using a Force Platform and Inertial Sensors for Balance Evaluation in Quiet Standing" Sensors 23, no. 10: 4933.

습 모델 중 하나로 여러 개의 의사 결정 트리를 생성하고 각 트리의 예측 결과를 결합하여 강력하고 안정적인 예측을 수행한다. 또한 각 트리를 학습할 때 랜덤하게 데이터를 샘플링한다. 이때, 중복을 허용한 부트스트랩 샘플을 사용하여 각 트리에 대한 학습 데이터를 생성한다. 각 트리가 서로 다른 데이터셋으로 학습되어 다양성을 증가시키고 랜덤하게 데이터를 추출 및 복원하기 때문에 과적합을 예방한다. 또한 RF는 병렬화가 가능하며, 각 트리가 독립적으로 학습되므로 하나의 트리가 잘못된 예측을 하더라도 다른 트리들이 이를 보완할 수 있어 모델의 안정성을 향상시킨다. RF는 각 특징의 중요도를 제공하여 어떤 특징이 예측에 가장 큰 영향을 주는지 이해할 수 있어 모델의 신뢰성을 높이고 입력으로 사용되는 압력 데이터의 어떠한 특징이 COM 예측에서 중요한 역할을 하는지 식별할 수 있다. 또한 대용량 데이터셋을 효과적으로 처리하는 장점이 있다. 모델을 통해 데이터를 학습 및 예측할 때 RandomForestRegressor를 사용하였고 이는 다양한 특징을 다루는 데 강점이 있다. 압력 데이터가 가진 패턴을 처리하는데 우수한 성능을 발휘한다. 이러한 이유로 압력 데이터를 기반으로 COM을 예측하는 본 연구에서 RF를 사용하였다.

1.4.2 CNN

압력 데이터를 기반으로 COM을 예측할 때 CNN 모델을 사용하였다. CNN은 이미지 데이터에서 우수한 성능을 보이는 모델이지만 시계열 데이터에서도 효과적으로 활용된다.

CNN 모델이 시계열 데이터에서 효과적으로 활용될 수 있는 이유 중 하나는 특징 추출이다. 압력 데이터는 시계열 데이터로 시간에 따른 특징이 있는데 CNN은 시간적인 특징을 잘 감지하고 학습할 수 있다. 특히, 데이터의 지역적인 특성을 인식하여 특정 시간대의 패턴을 파악하는 데 우수한 성능을 보인다. 또한 CNN은 계

층적인 특징을 학습할 수 있다. 다양한 합성곱 및 풀링 레이어를 통해 모델은 데이터의 다양한 시간적인 특징에 대해 대응할 수 있다. 작은 범위에서 발생하는 빠르게 변하는 특징과 큰 범위에서 나타나는 주기성과 같은 특징을 모두 잘 학습한다는 장점이 있다. 또 다른 특징으로는 데이터 공간화이다. CNN 모델은 2D 또는 1D 그리드로 데이터를 처리하여 데이터의 공간 구조를 이해하고 중요한 패턴을 추출할 수 있다. 본 연구에서는 1D 컨볼루션 레이어를 적용하였다. 추가로 Flatten과 Dense를 레이어를 사용하며 CNN 모델은 주기가 있고 반복적인 패턴이 있는 경우 우수한 성능을 보인다.⁶⁾ 또한 진이 학습을 통해 이미지 처리에서 학습된 모델을 가져와 시계열 데이터에 적용한다는 특징이 있다. 이미지 처리에서 나온 성능이 좋은 모델의 특징을 활용하여 COM 예측에 중요한 특징을 추출한다. 마지막으로 CNN을 사용한 이유는 복잡한 비선형 관계를 모델링 하는데 효과적이기 때문이다. 입력으로 사용한 압력 데이터는 여러 가지 요인과 상호작용이 존재한다. 특히, z 축을 예측해야 하기 때문에 학습 및 예측 모델링을 하는 데 비선형성이 존재하여 CNN을 사용하였다.

1.4.3 Bi-LSTM

기존 RNN은 시간에 따른 정보의 흐름을 모델링하려고 하지만, ‘장기 의존성’ 문제로 인해 실제로는 장기간의 정보를 유지하는데 어려움이 있다. 그러나 LSTM은 게이트 메커니즘을 도입하여 이 문제를 극복하여 장기간의 정보를 더 잘 유지하고 시계열 데이터의 패턴을 더 잘 학습할 수 있다. 그리고 LSTM을 확장한 모델이 Bi-LSTM이다. LSTM은 일방향으로 동작하지만 Bi-LSTM은 양방향으로 동작하여 이전과 이후의 정보를 모두 활용해서 출력을 생성한다. 또한 주기적인 패턴, 추세

6) P. Dileep, D. Das and P. K. Bora. "Dense Layer Dropout Based CNN Architecture for Automatic Modulation Classification." National Conference on Communications (NCC), Kharagpur, India, 2020, 1 - 5.

그리고 시간적 의존성을 높은 수준으로 캡처하고 시계열 데이터에서 발생할 수 있는 가변적인 시퀀스 길이에 대해 더욱 잘 처리한다는 특징이 있다.⁷⁾ 본 연구의 압력 데이터는 시계열 데이터로 시계열 데이터에서 높은 학습률과 예측률을 보이는 Bi-LSTM을 사용하였다.

제2장 연구 방법

2. 연구 방법

2.1 실험 데이터



실험을 통해 압력 데이터와 COM 데이터를 획득하였고 피실험자는 총 8명으로 남성 4명, 여성 4명으로 구성되었다. 데이터는 100Hz로 샘플링 하는 압력 발판 위에 20초 동안 가만히 서 있는 자세에서 추출되었다. 데이터의 다양성을 위해 눈을 뜨고 가만히 서 있는 자세(Eyes open)와 눈을 감고 가만히 서 있는 자세(Eyes close), 두가지 경우에서 데이터가 추출되었다. 압력 데이터는 실험이 진행되면 Real-term(Serial Capture) 프로그램에서 추출된다. 압력 데이터를 획득할 때 신체에 35개의 마커(그림 3)를 붙이고 120Hz로 샘플링하는 Vicon Nexus 프로그램의 motion capture system을 이용하여 같은 시간동안 35개 마커들의 위치 데이터를 획득 하였다. 이때 Vicon Nexus에서 카메라의 motion capture를 통해 센서의 위치

데이터를 얻으려면 먼저 Calibration작업이 우선되어야 한다. Calibration은 Vicon 시스템에서 카메라 시스템과 마커의 상대 위치를 정확하게 알아내어 3D 공간에서 운동을 추적하는데 사용된다. 먼저 카메라는 실험자를 기준으로 8방위 중 좌우를 제외한 6대의 고해상도 카메라를 사용하였다. Vicon 프로그램 내에서 Calibration작업을 실행하게 되면, 실험자는 마커가 붙어있는 막대를 사용하여 특수한 동작이나 패턴을 수행하게 된다. 이때 이 동작은 카메라가 마커를 여러 각도에서 관찰할 수 있도록 한다. 이때 막대는 실험자가 실험하게 되는 3D 공간을 채울 수 있도록 Calibration 작업을 진행한다. 이를 통해 6대의 카메라는 위 작업을 통해 3D 공간상 위치를 계산하고, 그 공간 내에서의 실험자의 마커를 더욱 쉽게 인식할 수 있다. Calibration 작업이 완료되면 Vicon은 motion capture에 사용될 프로파일을 생성한다. 실험의 시작과 끝을 파악하고 데이터의 일관성을 향상시키기 위해 실험의 시작과 끝에서 원발을 찍는 행동을 하였다.




<그림 2> 압력센서 발판

7) Farah Shahid, Aneela Zameer, Muhammad Muneeb. "Predictions for COVID-19 with Deep Learning Models of LSTM, GRU and Bi-LSTM." Chaos, Solitons & Fractals Volume 140 (2020): 779 - 960.



<그림 3> Vicon 프로그램 센서⁸⁾


8) "Full body modeling with Plug-in Gait," Vicon Nexus 2 Documentation, Vicon



<그림 4> Calibration용 막대⁹⁾

한 Patient에 대한 실험이 끝나면, 35개 마커에 대해 마킹 작업을 진행하였다. 마킹 작업은 Vicon 프로그램 내에서 진행되는데 각 마커의 위치에 해당하는 신체부위 (그림 3)를 매칭하는 작업이다. 먼저 실험 전체 영상 중, 35개의 마커가 모두 capture된 시점을 기준으로 Golf 마커 파일을 통해 마킹을 진행하면 <그림 5>와 같아진다.


9) "Full body modeling with Plug-in Gait," Vicon Nexus 2 Documentation, Vicon



<그림 5> 35개 마커 마킹 전과 후¹⁰⁾

이때 한 시점에서 35개의 마커에 모든 라벨링을 완료해도 실제로 다른 시점에서 동일한 마커로 인식하지 못하여 빈 마커로 남아있는 마커들이 있다. 이런 경우 Unlabeled Marker 작업을 통해 모든 시점의 라벨링되지 않은 마커들을 찾은 후, 알맞은 라벨을 입력해주어야 한다. 이후 라벨링 작업이 끝나면 Defragment Trajectory 작업을 통해 라벨링된 마커들을 동기화 시킨다. 이후 어떤 시점에 대하여 두 개의 마커가 인식되었거나 마커가 누락됐을 가능성이 있다. 이때는 누락된 마커 데이터를 자동으로 보정하는 Fill gap기능을 이용하였다. 이 작업을 수행하면 누락된 마커 데이터의 간격을 자동으로 보정하여 데이터의 일관성이 유지되도록 하

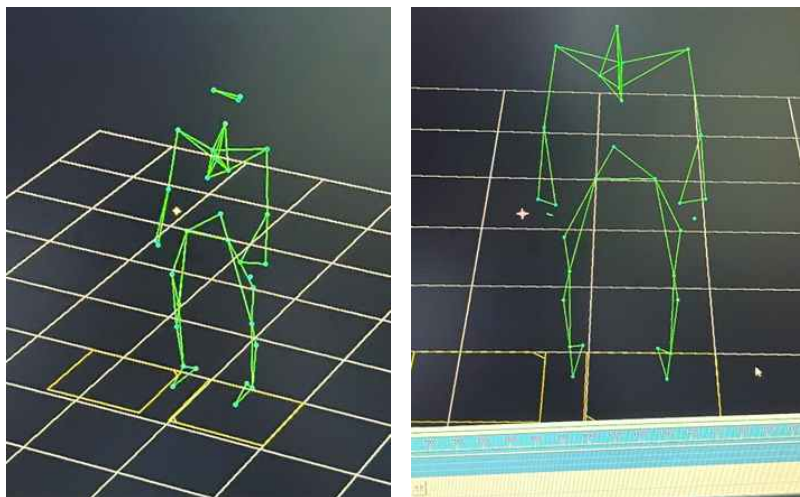
였다. 또한 Fill gap작업을 통해 원하지 않는 마커가 라벨링되거나 생길 경우 수동으로 라벨링하거나 Copy pattern의 기능을 활용하여 보정되어야 마커와 움직임이 동일한 마커를 선택해 pattern을 복사한 후, 동일하게 움직이도록 조정하는 등 마커의 위치를 조정하였다.(그림 6) 이후 보정된 시점을 기준으로 전후 상황을 비교하며 보정결과와 적합성을 검토하였다. 또한 마커 작업 도중에 카메라에 잡힌 노이즈(그림7) 같은 경우 발생한 시점 전후를 검토하며 노이즈임을 확인하고 마커를 삭제 하였다.




<그림 6> 마커 연결 작업 전과 후

기본 라벨링 작업이 완료된 후에 COM을 획득하기 위하여 Vicon 프로그램 내의 Pipeline작업을 사용했다. 이 작업을 수행하기 전에 Golf로 진행했던 라벨링 작업을 Plug-in-Gait로 다시 진행했다. 이후 Pipeline 작업(그림 8)을 통해 Gait modeling(그림 9)을 진행시켜 COM을 획득했다.

10) "Full body modeling with Plug-in Gait," Vicon Nexus 2 Documentation, Vicon




<그림 7> 노이즈 제거 작업



<그림 8> Pipeline 작업

Real-term 프로그램을 이용하여 얻은 압력 데이터는 발판 위에서 측정하기 때문에 x축과 y축에 대한 데이터만 획득하였고 COM 데이터는 카메라를 통해 motion을 찍고 이를 기반으로 COM을 획득하기 때문에 x축, y축, z축에 대한 데이터를 획득하였다.



<그림 9> Gait model

2.2 데이터 전처리


순차적으로 획득한 압력 데이터와 COM 데이터를 왼발을 찍는 순간을 기준으로 1차 데이터 전처리를 하였다. 또한 Real-term program은 100Hz로 샘플링하고 motion capture system은 120Hz로 샘플링 하기 때문에 데이터가 같은 시간만큼 획득되었어도 데이터의 행의 개수는 다르다. 따라서 butterworth low-pass filter와 spline 보간법을 이용하여 노이즈를 줄이고 결측치가 있는 부분을 채워 2차적으로

데이터를 전처리 하였다.¹¹⁾

2.3 인공지능 모델

2.3.1 모델 설계

그림 10은 전체적인 모델 설계의 순서도이다. 먼저 획득한 두 가지 데이터를 입력과 target으로 사용한다. 입력값인 압력 데이터는 78개의 특징벡터를 가지며 이를 기반으로 3가지 특징벡터를 갖는 COM 데이터를 target으로 활용해 COM을 예측한다. 획득한 데이터를 butterworth low-pass filter와 spline 보간법을 이용하여 전처리한다. 그리고 예측은 RF, CNN, Bi-LSTM, 3가지 모델을 이용한다. 마지막으로 예측한 모델의 평가는 r(Correlation Coefficient), RMSE, rRMSE를 사용한다.



<그림 10> 모델 설계 순서도

2.3.2 베이지안 최적화와 그리드서치

인공지능 모델의 성능을 향상시키기 위해 베이지안 최적화 방식을 많이 사용한다. 베이지안 최적화는 하이퍼파라미터를 최적화하고 함수를 최적화 할 때 사용되는 방식이다.¹²⁾ 그리드서치는 이산적인 하이퍼파라미터 값의 조합을 시도하여 최적

의 값을 찾는 방식이다. Bi-LSTM과 CNN은 베이지안 최적화 방식을 이용하고 RF는 그리드서치 방식을 이용하여 최적의 성능을 보이는 하이퍼파라미터 값을 선정하였다. 표 1은 모델을 통해 COM 값을 예측할 때 사용한 레이어 및 파라미터 구성이며 베이지안 최적화를 하기 위해 범위를 설정한 내용이다. Bi-LSTM에서는 Bi-LSTM 레이어 3개, 드롭아웃 레이어 3개 그리고 완전 연결층을 2개의 최적화를 진행하였다. CNN에서는 컨볼루션 레이어와 완전 연결층의 최적화를 진행하였고 RF에서는 두 개의 파라미터에 대해 그리드서치를 진행하였다. 베이지안 최적화 및 그리드서치를 통해 가장 좋은 성능을 보였을 때의 값들을 정리한 내용이 표 2이다.

표 2를 보면 Bi-LSTM에서 최적의 Bi-LSTM 레이어 유닛 값이 나왔다. 첫 번째 레이어는 239개의 유닛, 두 번째 레이어는 974개, 세 번째 유닛은 436개의 유닛이 가장 최적의 값이다. 다음은 드롭아웃 레이어 비율이다. 첫 번째 드롭아웃 레이어의 최적의 비율은 0.9, 두 번째 레이어는 0.916이다. 이후 완전 연결층으로 연결되며 첫 번째 완전 연결층은 41개, 두 번째 완전 연결층은 21개가 최적의 값이다. 그리고 그 사이에 배치되는 드롭아웃 레이어의 비율은 0.806이다. CNN의 경우 컨볼루션 레이어의 필터는 99개, 커널 크기는 2, 완전 연결층의 뉴런 개수는 171개가 최적의 값이다. 마지막으로 RF는 두 하이퍼파라미터 모두 10이 최적의 값이다. 최적화를 통해 획득한 값들을 모델을 구성할 때 적용하였다.

11) Lee, Yechan, Yeongryeol Choi, Hyungtae Cho, and Junghwan Kim. "Prediction of Distillation Column Temperature Using Machine Learning and Data Preprocessing." Korean Chemical Engineering Research 59, no. 2 (May 1, 2021): 191 - 99

12) 최용욱, et al. 베이지안 최적화를 이용한 암상 분류 모델의 하이퍼 파라미터 탐색. 지구물리와 물리탐사, 2020, 23.3: 157-167.

Phase	Hyperparameter	Range
Bi-LSTM	Bi-LSTM layer 1	99-990
	Dropout layer	0.5-0.95
	Bi-LSTM layer 2	99-990
	Dropout layer	0.5-0.95
	Bi-LSTM layer 3	99-990
	Fully connected layer 1	10-50
	Dropout layer	0.5-0.95
	Fully connected layer 2	Fully connected layer 1/2
CNN	Conv1D layer-filters	32-128
	Conv1D layer-kernel size	2-5
	Fully connected layer 1	64-256
RF	n_estimators	1-10
	max_depth	0-20

Phase	Hyperparameter	Value
Bi-LSTM	Bi-LSTM layer 1	239
	Dropout layer	0.900
	Bi-LSTM layer 2	974
	Dropout layer	0.916
	Bi-LSTM layer 3	436
	Fully connected layer 1	41
	Dropout layer	0.806
	Fully connected layer 2	21
CNN	Conv1D layer-filters	99
	Conv1D layer-kernel size	2
	Fully connected layer 1	171
RF	n_estimators	10
	max_depth	10

<표 1> Bayesian optimization range <표 2> Bayesian optimization value

2.3.3 정규화

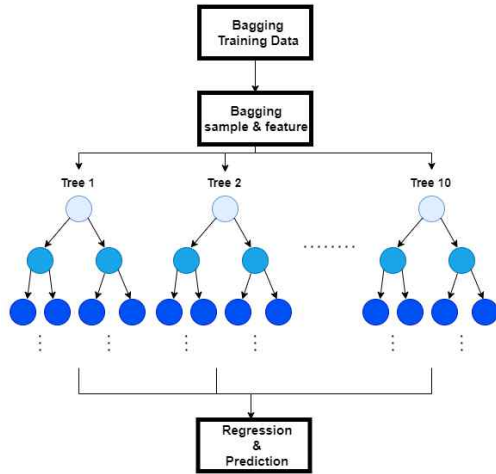
실험을 통해 획득한 데이터를 모델에 적용시킬 때 성능을 향상시키기 위해 정규화를 진행하였다. 정규화는 MinMaxScaler 방법을 적용하였는데 이는 각 특성의 최소값을 0으로, 최대값을 1로 조정한다. 즉, 모든 특성을 [0,1] 범위로 압축하는데 데이터의 분포는 변환하지 않으면서 범위를 조정한다. MinMaxScaler는 먼저 데이터에서 최소값을 뺀다. 이렇게 했을 경우 최소값은 0이 된다. 그리고 그 값을 최대값과 최소값의 차이로 나눈다. 이렇게 했을 경우 최대값은 1이 되며 이를 (1)의 식으로 표현할 수 있다.¹³⁾ 정규화는 RF, CNN, Bi-LSTM에 모두 적용되었다.

13) KWAK, Jee-yoon, et al. BICF: Collaborative Filtering Based on Online Behavior Information. In: Proceedings of the Korea Information Processing Society Conference. Korea Information Processing Society, 2020. p. 401-404.

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

2.3.4 RF

COM을 예측하기 위해 RandomForestRegressor를 사용하여 회귀 분석을 수행하고, 10-fold 교차 검증을 통해 모델을 평가하는 프로세스를 구현하였다. Real-term 프로그램을 통해 얻은 압력 데이터와 motion capture system을 통해 얻은 COM 데이터를 연결(concatenation)하여 변수에 저장하고 10-fold를 수행하였다. 각 fold마다 데이터를 학습 및 검증 세트로 나누고 정규화가 진행된 후 RandomForestRegressor 모델을 학습하였다. 정규화를 먼저 진행하지 않고 각 fold 내에서 정규화를 진행하면 총 10번의 정규화가 이루어진다. 정규화 후 10-fold를 하게 되면 데이터 누출이 발생할 수 있어 각 fold 내에서 정규화를 진행하였다. 또한 정규화를 먼저 진행하면 각 fold에서의 데이터 특성이 모델 학습에 영향을 미쳐 모델의 편향이 생길 수 있다. 따라서, 각 fold에서 정규화를 별도로 진행하여 훈련 데이터와 검증 데이터를 엄격하게 분리하고 일반화 성능을 더 정확하게 추정하여 모델 평가의 신뢰성을 높였다.




<그림 11> RF architecture¹⁴⁾

2.3.5 CNN

학습에 이용한 CNN 모델은 그림 12과 같다. 입력하는 전체 데이터의 형태는 (1,78)로 reformat하여 입력하였다. 그리고 입력하는 데이터는 시계열이므로 CNN 회귀에서 1D convolutional neural networks를 사용한다. Convolution 레이어는 일반적인 형태로 convolution, 배치 정규화, ReLU함수가 적용된다. 첫번째 컨볼루션 레이어는 (1,78)의 형태로 입력되어 99개의 필터를 사용하고 커널 크기는 2이다. 그리고 ReLU 함수를 통해 출력을 생성한다. 컨볼루션 레이어 뒤에 Maxpooling1D 레이어가 오며 입력 부분 영역에서 최대값을 취해 다운 샘플링을 수행한다. 이때 pool

14) KIM, R. M.; KIM, K. M.; AHN, Johng-Hwa. Comparison between random forest and recurrent neural network for photovoltaic power forecasting. J Korean Soc Environ Eng, 2021, 43.5: 347-355.

사이즈는 1이다. Maxpooling1D 이후 Flatten에서 입력을 1차원으로 평평하게 펼치고 모든 입력을 연결하여 완전 연결층에 전달한다. Flatten은 컨볼루션 신경망 다음에 완전 연결층을 추가할 때 사용하며 컨볼루션과 pooling 레이어의 출력을 평평하게 하여 이후의 완전 연결층에서 처리가 가능하다.¹⁵⁾ 완전 연결층(Dense)에서는 가중치와 편향을 사용하여 입력과 출력 간의 관계를 학습한다. Dense는 모델의 복잡한 패턴을 학습하는데 많이 사용되어 본 모델에 적용시켰다. 총 2개의 완전 연결층이 있으며 첫번째 완전 연결층은 171개의 뉴런을 가지며 ReLU 활성화 함수를 사용한다. 이후 두번째 완전 연결층으로 들어가며 선형 함수를 활성화 함수로 사용한다. 두번째 완전 연결층을 통해 3개의 출력이 나온다. 최종적으로 MinMaxScaler 방식으로 정규화를 진행하고 모델의 학습에서 'adam' optimizer를 사용하며 손실 함수로는 'mean squared error(mse)'를 사용한다.



<그림 12> CNN architecture

2.3.6 Bi-LSTM

입력하는 데이터는 (1,78)로 reformat하여 입력하였고 CNN모델과 동일하게 10-fold를 사용하여 코드를 진행하였다. Bi-LSTM의 모델 구조는 그림 13과 같다.

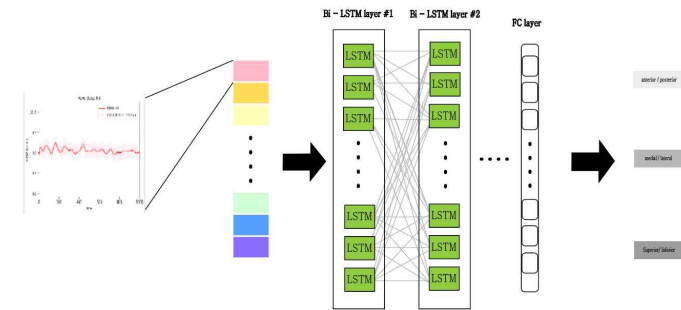
15) PHAN, Huy, et al. Robust audio event recognition with 1-max pooling convolutional neural networks. arXiv preprint arXiv:1604.06338, 2016.

사용한 레이어는 대표적으로 Bi-LSTM레이어, 드롭아웃 레이어, Dense레이어이다. 레이어 내부에는 유닛이 존재하는데 이는 신경망의 기본 구성 요소로 입력과 출력 간의 가중치를 가지는 노드이다. 즉, 유닛은 신경망이 정보를 처리하고 학습하는 단위이다. 드롭아웃 레이어는 신경망에서 과적합을 방지하는 데 도움을 주는 정규화 기법 중 하나이다. 또한 각 훈련 단계에서 랜덤하게 뉴런을 비활성화하므로 다양한 부분 집합의 네트워크를 훈련시키게 되어 다양성을 증가시키고 훈련 중에 모델에 노이즈를 주어 모델이 더 견고하게 학습되도록 한다.¹⁶⁾ 모델은 (1,78) 형태의 입력 값이 첫번째 Bi-LSTM 레이어로 입력된다. 첫번째 Bi-LSTM 레이어 다음에는 드롭아웃 레이어가 위치한다. 두번째 Bi-LSTM 레이어는 974개의 유닛을 가지며 이 또한 시퀀스를 반환한다. 그 다음 두번째 드롭아웃 레이어가 위치하고 그 다음 세번째 Bi-LSTM레이어가 위치하며 Dense 레이어로 들어간다. 완전 연결층(Dense)은 주로 Bi-LSTM과 같은 순환 레이어의 출력을 사용하여 최종 예측을 수행하는 데 사용된다. 2개의 완전 연결층이 사용되었고 첫번째 완전 연결층 이후에 드롭아웃 레이어를 배치하였다. 두번째 완전 연결층 다음으로 Flatten 레이어가 위치하고 Flatten 레이어를 거치고 3개의 유닛을 갖는 마지막 Dense 레이어를 지나게 된다. 여러가지 레이어들을 거쳐 최종 출력은 (1,3)의 형태를 가진다. 최종적으로 (1,78)의 입력으로 (1,3)의 형태를 출력하는 모델을 구성하였으며 (1,3)에서 3은 각각 x축, y축, z축을 의미한다.

최종적으로 MinMaxSclaer 방식으로 정규화를 진행한 후 모델의 학습에서는 ‘adam’ optimizer를 사용하며 손실 함수로는 ‘mean squared error(mse)’를 사용한다. 또한 훈련 시 조기 종료(early stopping)를 사용하여 검증 손실을 모니터링하고 일정한 epoch동안 개선되지 않으면 훈련을 중지하여 과적합을 방지하도록 하였다.

16) LEE, Gyeong-Hoon; JO, Jeil; PARK, Cheong Hee. Prediction of Jamming Techniques by Using LSTM. Journal of the Korea Institute of Military Science and Technology, 2019, 22.2: 278-286.

본 모델은 Bi-LSTM, 드롭아웃, Flatten 그리고 Dense 레이어를 조합하여 만들었다. Bi-LSTM이 시퀀스를 학습하고, Dense 레이어가 이를 기반으로 최종 예측을 수행하며, Flatten레이어가 입력을 평평하게 펼치고 드롭아웃이 일반화를 향상시킨다. 이와 같이 구성하면 최종 예측 수행 성능이 높아지고 과적합을 방지하며 입력과 출력 간의 비선형 매핑을 수행하는 데 도움이 된다.¹⁷⁾



<그림 13> Bi-LSTM architecture

2.4 예측 모델 평가지표

예측 성능을 검증하기 위해 예측 결과가 실제 데이터가 얼마나 일치하는지 그리고 얼마나 차이가 나는지 확인해야 한다. 이를 위해 평가지표는 r, RMSE, rRMSE를 사용하였다.

r(Correlation Coefficient)은 실제 데이터와 예측 결과 간의 선형 상관관계를 나타낸다. 값의 범위는 [-1,1]이며 1에 가까울수록 양의 선형 상관관계이고 0에 가까울수록 상관관계가 없음을 나타낸다. RMSE는 오차의 제곱을 평균한 후 제곱근을

17) LEE, Gyeong-Hoon; JO, Jeil; PARK, Cheong Hee. Prediction of Jamming Techniques by Using LSTM. Journal of the Korea Institute of Military Science and Technology, 2019, 22.2: 278-286.

취한 값으로 값이 작을수록 실제 데이터와 예측 결과가 일치한다. 이를 식으로 나타내면 (2)와 같이 나타낼 수 있다. 본 연구에서 RMSE의 단위는 mm(millimeter)이다. rRMSE는 RMSE를 최대값과 최소값의 차이로 나눈 값에 100%를 곱한 값으로 퍼센트로 성능 평가를 확인할 수 있다.¹⁸⁾ rRMSE를 식으로 나타내면 (3)과 같이 나타낼 수 있다.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2} \quad (2)$$

$$rRMSE = \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2}}{\max(x_i) - \min(x_i)} \times 100\% \quad (3)$$

제3장 연구 결과

3.연구결과

3.1 인공지능 모델 학습 결과

3.1.1 모델 성능평가

표 3은 3가지 모델의 평가지표 결과이다. 평가지표는 r, RMSE, rRMSE이고 x(medial/lateral)축, y(anterior/posterior)축, z(superior/inferior)축을 따로 결과를 도출하였다. 먼저 상관계수를 보면 x축과 y축은 RF가 각각 0.970, 0.988이고 Bi-LSTM이 각각 0.950, 0.978이다. z축에서는 Bi-LSTM의 상관계수가 0.928, RF의 상관계수가 0.895이다. 그리고 y축에서는 CNN이 RF, Bi-LSTM과 유사한 상관계수를 보였지만 z축에서는 약 0.1 정도로 큰 차이를 보였다.

Bi-LSTM, CNN, RF의 rRMSE(%) 결과는 각각 5.612 ~ 8.314(%), 7.746 ~ 15.021 (%), 2.221 ~ 7.473(%)이다. 각 축에 대해서 rRMSE 결과를 보면 x축(medial/lateral)에서 Bi-LSTM은 6.317±1.585%, CNN은 8.157±2.261% 그리고 RF는 2.970±3.502%이다. y축(anterior/posterior)에서 Bi-LSTM은 5.612±1.457%, CNN은 7.746±2.709% 그리고 RF는 2.221±2.801%이다. 마지막으로 z축(superior/inferior)에서 Bi-LSTM은 8.314±2.780%, CNN은 15.021±3.631% 그리고 RF는 7.473±8.445%이다. 모델의 안정성을 판단하기 위해 각 모델의 rRMSE결과의 표준편차를 백분율로 나타내었다. 표 4를 보면 Bi-LSTM의 표준편차 백분율은 25.091 ~ 33.438(%), CNN

18) GHORBANI, Mohammad Ali, et al. Application of firefly algorithm-based support vector machines for prediction of field capacity and permanent wilting point. Soil and Tillage Research, 2017, 172: 32-38.

은 22.375 ~ 34.973(%) 그리고 RF는 113.007 ~ 126.114(%)이다. 변동이 가장 적고 안정적인 모델은 Bi-LSTM이고 가장 변동이 큰 모델은 RF이다.

	X(medial/lateral)			Y(anterior/posterior)			Z(superior/inferior)		
	r	RMSE(mm)	rRMSE(%)	r	RMSE(mm)	rRMSE(%)	r	RMSE(mm)	rRMSE(%)
Bi-LSTM	0.950	0.570 ± 0.143	6.317 ± 1.585	0.978	1.094 ± 0.284	5.612 ± 1.457	0.928	0.332 ± 0.111	8.314 ± 2.780
CNN	0.918	0.736 ± 0.204	8.157 ± 2.261	0.973	1.510 ± 0.528	7.746 ± 2.709	0.822	0.599 ± 0.145	15.021 ± 3.631
RF	0.970	0.268 ± 0.316	2.970 ± 3.502	0.988	0.433 ± 0.546	2.221 ± 2.801	0.895	0.305 ± 0.361	7.473 ± 8.445

<표 3> 3가지 모델의 각 축에 대한 성능 평가 결과

	X(medial/lateral)		Y(anterior/posterior)		Z(superior/inferior)	
	rRMSE(%)	standard error(%)	rRMSE(%)	standard error(%)	rRMSE(%)	standard error(%)
Bi-LSTM	6.317 ± 1.585	25.091	5.612 ± 1.457	25.962	8.314 ± 2.780	33.438
CNN	8.157 ± 2.261	27.718	7.746 ± 2.709	34.973	15.021 ± 3.631	22.375
RF	2.970 ± 3.502	117.912	2.221 ± 2.801	126.114	7.473 ± 8.445	113.007

<표 4> 3가지 모델의 각 축에 대한 표준편차의 백분율

3.1.2 EO와 EC 결과

표 4는 표 3에서 EO(Eyes open)와 EC(Eyes close)를 분리하였을 때 Bi-LSTM, CNN, RF 모델에 대한 평가지표 결과이다. 표 4에서 EO의 상관계수 r을 보면 0.903 ~ 0.997로 RF가 가장 높은 상관계수를 보이고 그 다음은 0.925 ~ 0.972로 Bi-LSTM이다. 가장 낮은 상관계수를 보인 모델은 0.828 ~ 0.965로 CNN이다. EC의 상관계수 r을 보면 0.888 ~ 0.979로 RF가 가장 높은 상관계수를 보이고 그 다음은 0.874 ~ 0.923로 Bi-LSTM이다. 가장 낮은 상관계수를 보인 모델은 0.746 ~ 0.929로 CNN이다.

EO의 Bi-LSTM, CNN, RF의 rRMSE 결과는 각각 5.627 ~ 8.479 (%), 7.636 ~

14.707(%), 1.949 ~ 7.529(%)이다. 그리고 EC의 Bi-LSTM, CNN, RF의 rRMSE 결과는 각각 6.949 ~ 10.755(%), 7.982 ~ 15.257(%), 2.473 ~ 7.754(%)이다. 각 축에 대해 EO에서 rRMSE의 결과를 보면 x축에서 Bi-LSTM은 6.262±1.518%, CNN은 7.636±1.640% 그리고 RF는 2.948±2.682%이다. y축에서 Bi-LSTM은 5.627±1.698%, CNN은 7.874±1.852% 그리고 RF는 1.949±1.431%이다. 마지막으로 z축에서 Bi-LSTM은 8.479±2.851%, CNN은 14.707±2.651% 그리고 RF는 7.529±7.379%이다. EC에서 rRMSE의 결과를 보면 x축에서 Bi-LSTM은 6.949±1.618%, CNN은 8.589±2.228% 그리고 RF는 2.992±4.112%이다. y축에서 Bi-LSTM은 7.556±4.058%, CNN은 7.982±0.795% 그리고 RF는 2.473±3.606%이다. 마지막으로 z축에서 Bi-LSTM은 10.755±5.027%, CNN은 15.257±3.877% 그리고 RF는 7.754±10.355%이다.

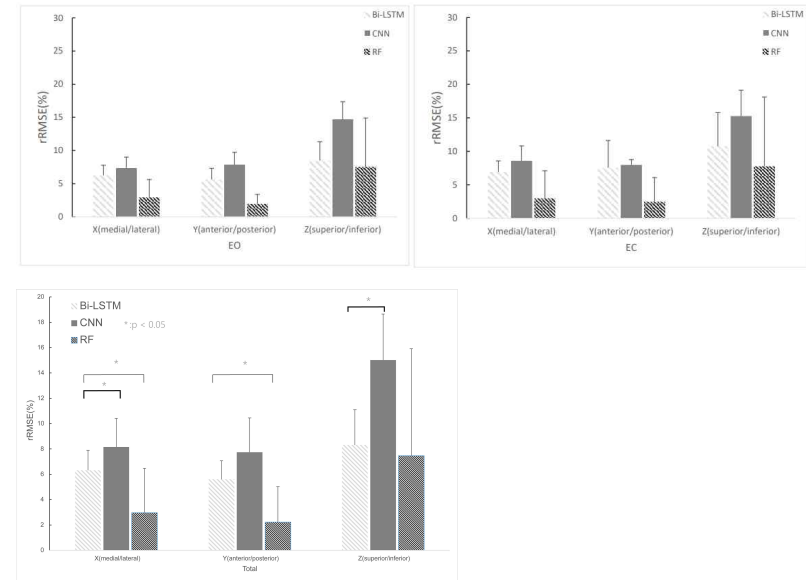
EO와 EC 모두 Bi-LSTM, CNN, RF 모델 중 RF가 모델이 가장 상관계수 값이 높고 RMSE, rRMSE 값이 낮았다. 그리고 눈을 감고 있을 때 시각이 차단되기 때문에 신체의 중심을 잡기가 어려워 EC에서 대체로 예측을 더 못한다. 실제로 EO와 EC의 RF에 대한 rRMSE의 표준편차를 비교했을 때 EC에서 표준편차가 더 커 예측값의 변동성이 크다는 것을 보여준다. 또한 표 3과 표 5의 결과를 보았을 때 상관관계가 높으면서 rRMSE가 낮은 축, 즉, 예측을 가장 잘하는 축은 y축이고, 가장 예측을 못하는 축은 z축이다.

		X(medial/lateral)			Y(anterior/posterior)			Z(superior/inferior)		
		r	RMSE(mm)	rRMSE(%)	r	RMSE(mm)	rRMSE(%)	r	RMSE(mm)	rRMSE(%)
EO	Bi-LSTM	0.947	0.565 ± 0.137	6.262 ± 1.518	0.972	1.097 ± 0.331	5.627 ± 1.698	0.925	0.339 ± 0.114	8.479 ± 2.851
	CNN	0.899	0.689 ± 0.148	7.636 ± 1.640	0.965	1.535 ± 0.361	7.874 ± 1.852	0.828	0.588 ± 0.106	14.707 ± 2.651
	RF	0.983	0.266 ± 0.242	2.948 ± 2.682	0.997	0.380 ± 0.279	1.949 ± 1.431	0.903	0.301 ± 0.295	7.529 ± 7.379
EC	Bi-LSTM	0.934	0.627 ± 0.146	6.949 ± 1.618	0.923	1.473 ± 0.791	7.556 ± 4.058	0.874	0.430 ± 0.201	10.755 ± 5.027
	CNN	0.884	0.776 ± 0.201	8.589 ± 2.228	0.929	1.556 ± 0.155	7.982 ± 0.795	0.746	0.610 ± 0.155	15.257 ± 3.877
	RF	0.964	0.270 ± 0.371	2.992 ± 4.112	0.979	0.482 ± 0.703	2.473 ± 3.606	0.888	0.310 ± 0.414	7.754 ± 10.355

<표 5> EO, EC에서 3가지 모델에 대한 각 축의 성능 평가 결과


3.1.3 예측 결과 Plot & Graph

그림 14는 표 3과 표 5의 결과 중 3가지 모델에 대한 rRMSE의 결과를 그래프로 나타낸 것이다. EO와 EC 그래프를 보면 RF의 rRMSE가 가장 낮고 CNN의 rRMSE가 가장 크다. 하지만 Bi-LSTM과 CNN에 비해 표준편차가 크다. 그리고 EO에 비해 EC의 rRMSE가 3가지 모델 모두 대체적으로 높고 x축, y축에 비해 z축의 rRMSE 값이 크다. 특히 토탈 그래프에서 CNN의 z축 rRMSE는 약 18% 정도의 큰 값을 보인다.



<그림 14> EO, EC, Total rRMSE 결과 그래프

예측 모델의 성능을 검증하기 위해서 COM 값을 예측한 결과를 각 축에 따라 Plotting하여 확인하였다. Plot에서 x축은 실험 대상자의 COM 측정 작업 시간을 100%로 정규화 한 값이고 y축은 COM 값을 나타낸다. 또한 Bi-LSTM, CNN, RF 모델에 의해 예측된 COM 값과 실제 COM 값의 대푯값을 보여준다. 표 3에서 확인한 결과는 각 축에 따른 결과와 각 모델에 따른 결과였다. 그리고 그림 15를 보면 x축, y축에 비해 z축의 예측 결과가 좋지 않다. 그리고 모든 축에서 Bi-LSTM과 CNN에 비해 RF에서 뒤는 값이 많다. 이는 표4에서 확인한 표준편차의 변동성이 RF가 가장 크다는 내용과 일치한다.



<그림 15> COM 예측 결과 plot

3.2 모델 검증

3.2.1 ANOVA & Post Hoc Test

3가지 모델을 통해 COM 예측을 진행하고 결과를 확인하였는데 모델을 검증하기 위해선 각 모델 간의 차이를 확인해야 한다. 3가지 모델 간의 차이를 확인하기 위해 ANOVA(분산분석)와 Tukey의 사후분석(Post Hoc Test)을 진행하였다. ANOVA는 3개 이상의 그룹 간의 평균 차이를 검정하는 통계적 방법이다. 또한 3가지 모델 간 평균 차이 비교를 통해 차이가 우연히 발생한 것인지 통계적으로 평가하여 예측 결과가 여러 그룹 간에 유의미한 차이가 있는지 확인할 수 있다. 본 연구에서는 RF, CNN, Bi-LSTM의 세 모델의 성능을 비교한다. 여기서 ANOVA의 귀무가설은 3가지 모델의 평균이 동일하다고 가정하는 것이다. 또한 p값은 귀무가설이 참일 때 혹은 두 모델 사이의 차이가 우연히 일어난 것일 때 얻을 수 있는 결과보다 더 극단적인 결과를 얻을 확률로 일반적으로 사용하는 기준은 0.05(5%)이다. ANOVA를 진행하면 3가지 모델 사이에 차이가 존재하는지 아닌지에 대해 알 수 있다. 만약 차이가 존재했을 때 어떤 모델이 다른 모델과 다른지 구체적으로 알기 위해 사후 분석을 진행한다. 대표적인 사후 분석은 Tukey's HSD(Honestly Significant Difference) test이다. 이 방법을 통해 어떤 모델 간의 차이가 유의미한지 확인할 수 있다. ANOVA와 사후분석을 통해 얻은 결과를 이용하여 3가지 모델 간의 성능을 비교한다. 통계적 검증을 통해 모델의 예측 결과가 우연에 의한 것인지 아니면 실제로 그룹 간 차이가 있는지 확인하여 모델의 신뢰성을 향상시킬 수 있다.

본 연구에서는 분석을 위해 Python의 statsmodels 라이브러리에서 제공하는 pairwise_tukeyhsd 함수를 사용하였다. 이 함수는 Tukey의 HSD(Honestly

Significant Difference) 검정을 수행하여 여러 그룹 간의 평균 차이가 통계적으로 유의미한지를 판단한다. 또한 scipy 라이브러리의 stats 모듈에서 제공하는 f_oneway 함수를 사용하였다. 이 함수는 일원분산분석(One-way ANOVA)을 수행하여, 3개 이상의 모델 간에 평균의 차이가 통계적으로 유의미한지를 판단한다. 이 방법 또한 여러 모델 간의 차이를 한 번에 비교하기 위한 방법이다.¹⁹⁾

3.2.2 결과

	X(medial/lateral) / Y(anterior/posterior) / Z(superior/inferior)		
	rRMSE(%)	ANOVA	Post Hoc Test
1. Bi-LSTM	5.612 ~ 8.314		
2. CNN	7.746 ~ 15.021	F = 19.1 (p < 0.05)	1, 2 > 3
3. RF	2.221 ~ 7.743		

<표 6> ANOVA와 Post Hoc Test 결과

표 6은 ANOVA 방식과 사후분석을 진행한 결과이다. F-값은 분산의 비율을 나타내며 ANOVA 진행결과 19.1(p<0.05)가 나왔다. F-값을 통해 모델 간 유의미한 차이가 있다는 것을 알 수 있어 귀무가설을 기각할 수 있다. 하지만 ANOVA 방식만으로는 어떤 모델 사이에서 차이가 있는지 알 수 없다. 따라서 어떤 모델 사이에서 차이가 있는지 확인하기 위해 사후분석(Post Hoc Test)을 진행하였다. 각 축에서 p값을 확인해보면 x축에서 Bi-LSTM과 RF 간의 rRMSE p값은 p<0.05, Bi-LSTM과 CNN에서는 p<0.05이다. y축에서 Bi-LSTM과 RF에서는 p<0.01이고 z축에서 Bi-LSTM과 CNN에서는 p<0.01이다. p값의 모델 간의 관계는 그림 14의 Total 그래프에서 확인할 수 있다. 사후분석 결과는 1,2 > 3으로 나왔는데 1은

19) Youn, S. H., Sim, T., Choi, A., Song, J., Shin, K. Y., Lee, I. K., Heo, H. M., Lee, D., and Mun, J. H., 2015, "Multi-Class Biological Tissue Classification Based on a Multi-Classifer: Preliminary Study of an Automatic Output Power Control for Ultrasonic Surgical Units," Comput. Biol. Med., 61, pp. 92 - 100.

Bi-LSTM, 2는 CNN, 3은 RF를 의미한다. 즉, RF가 가장 작은 rRMSE 값을 보였고 ANOVA와 사후분석을 통해 모델 간 유의미한 차이가 존재한다는 것을 확인하였다.

제4장 논의

4. 논의

4.1 인공지능 모델 예측 결과 비교 및 원인 분석

먼저 EO와 EC의 결과를 보았을 때 EC의 성능지표 결과가 낮았다. EO와 EC 모두 조용히 서 있는 상태에서 데이터를 획득하였지만 EC의 경우 시각이 차단되기 때문에 중심을 잡기 힘들어 압력 데이터의 변동성이 컸다. 즉, EC에서 압력 데이터의 변동성이 크고 EO 보다 이상치의 범위가 커 예측값의 오차가 컸다고 생각할 수 있다.

본 연구는 압력 데이터를 기반으로 인공지능 모델을 이용하여 x축, y축 그리고 z축에 대한 COM 값을 예측한다. x축과 y축에 대한 압력 데이터를 획득했을 때 압력이 들어가는 방향이 z축이기 때문에 x축, y축과 z축 간의 상관관계가 존재한다. 또한 Target인 COM 데이터에는 x축, y축 그리고 z축에 대한 데이터가 모두 존재한다. 따라서 압력발판 센서를 통해 x축과 y축에 대한 데이터만 획득하지만 압력이 가해지는 방향이 z축 방향이기에 획득한 데이터는 z축과 상관관계가 존재한다. 따라서 z축에 대한 COM 값도 예측이 가능하다. 인공지능 모델을 이용하여 COM을 예측했을 때 x축과 y축에 대한 예측 성능보다는 결과가 좋지 않지만 z축에서 Bi-LSTM의 rRMSE의 경우 10% 내외로 유의미한 예측 성능을 보였다.

압력 데이터를 기반으로 COM을 예측한 모델들을 검증하기 위해 분산분석(ANOVA)와 사후분석(Post Hoc Test)를 진행하였다. 분석은 rRMSE 값을 기준으

로 하였고 ANOVA 진행결과 $F=19.1(p<0.05)$ 로 모델 간 유의미한 차이가 있다는 것을 확인하고 어떤 모델 간의 차이가 있는지 확인하기 위해 사후분석을 진행하였다. 사후분석 진행결과 Bi-LSTM, CNN > RF이라는 결과가 나와 모델 간의 유의미한 차이가 존재한다는 것을 확인하였다.

본 연구에서 입력으로 사용하기 위해 실험을 통해 얻은 데이터는 압력 데이터이다. 압력 데이터는 약 30초 동안 조용히 서 있는 자세에서 획득하였기에 시계열 데이터이다. 시계열 데이터에 대한 특징은 추세, 주기, 순환 등이 있다. 추세는 데이터가 시간에 따라 증감하는 경향이고 주기는 반복되는 패턴이나 주기이며 순환은 주기와 유사하지만 일정한 주기가 정해져 있지 않고 일반적으로 더 긴 주기를 의미한다. 임력값인 압력 데이터의 경우 시계열 데이터이지만 조용히 서 있는 자세에서 데이터를 획득했기 때문에 크게 증감하거나 주기적으로 반복되는 패턴이 뚜렷하지 않다. 또한 압력 데이터는 성별 및 몸무게에 따라 값이 차이가 많이 나는데 본 연구에서는 총 8명에 대한 압력 데이터를 획득하였고 성별, 몸무게 그리고 키가 다양하여 특정한 주기가 반복되거나 큰 변동이 있지 않았다. 이러한 데이터 특징이 3가지 모델 중 RF가 가장 높은 상관계수와 가장 낮은 RMSE, rRMSE 값을 나타낸 이유라고 생각한다. 하지만 RF 모델의 예측 결과값의 수치는 뛰어났지만 rRMSE 및 plot에서 표준편차가 Bi-LSTM과 CNN 보다 월등히 컸다. 100%가 넘어가는 표준편차 백분율로 인해 RF 모델은 본 연구에서 가장 좋은 성능을 보이는 모델이 아니다. 반면에 rRMSE가 모든 축에서 10% 내외이고 표준편차 백분율이 25.091 ~ 33.438(%)로 가장 안정적인 모델은 Bi-LSTM이다.

4.2 한계점

압력 데이터는 성별과 몸무게가 다양하였지만 피실험자가 총 8명으로 대상이 적

있다는 한계점이 존재한다. 또한 피실험자 8명 모두 연령도 23~27세로 제한적이었다.

COM 데이터의 경우 압력 데이터를 획득할 때 같이 획득하여 일관성은 확보하였지만 프로그램 내에서 COM 값을 획득할 때 노이즈가 존재하였다. 또한 프로그램이 인식하기 위한 센서를 부착할 때 맨몸에서 진행하는 것이 가장 바람직하지만 옷을 입은 상태로 진행하여 실제 사람의 무게중심과 오차가 존재하였다. COM 데이터를 획득할 때 노이즈와 오차를 줄이면 예측 성능이 좀 더 향상되었을 것이다.

인공지능 모델은 다양한 데이터를 기반으로 학습하였을 때 예측 성능이 올라가는데 본 연구는 8명의 피실험자에 대한 데이터로 학습하여 데이터셋이 부족하다. 또한 인공지능 자체에서 데이터와 알고리즘의 편향성 문제가 아직 존재한다. 학습 데이터에 편향이 있으면 인공지능의 판단에도 영향을 미칠 수 있다.

위와 같은 한계점들이 존재해 모델 성능, 특히 RF의 rRMSE 표준편차 백분율이 컸다 생각된다. 한계점들을 해결하면 3가지 모델의 성능이 향상되어 COM을 더욱 안정적이며 높은 성능으로 예측할 수 있을 것이다.

제5장 결론

5. 결론

본 연구는 실험을 통해 압력 데이터와 COM 데이터를 획득하고 이를 기반으로 인공지능 모델을 통해 COM을 예측하였다. 압력 데이터는 압력발판 센서를 통해 획득하고 COM 데이터는 motion capture system인 Vicon 프로그램을 이용하여 획득하였다. 획득한 데이터를 전처리하고 3가지 인공지능 모델의 입력과 Target으로 사용하였다. 모델은 RF, CNN 그리고 Bi-LSTM, 3가지를 활용하였다. COM 예측값과 실험을 통해 획득한 실제 COM 값을 비교하기 위한 평가지표는 r(Correlation Coefficient), RMSE, rRMSE를 사용하였다. 예측 결과는 x축, y축 그리고 z축에 대해 따로 결과값을 도출하였는데 상관관계가 가장 높으며 rRMSE가 가장 작은 모델은 RF 모델이었다. 하지만 RF 모델의 예측 결과는 표준편차의 백분율이 113.007 ~ 126.114(%)로 신뢰하고 사용할 수 있는 모델은 아니다. 반면에 Bi-LSTM은 rRMSE가 5.612 ~ 8.314(%)이고 표준편차 백분율은 25.091 ~ 33.438(%)로 rRMSE가 낮으면서 가장 안정적으로 COM을 예측하였다. 실험은 눈을 뜬 상태와 눈을 감은 상태, 2가지 조건에서 진행되어 EO(Eyes open)와 EC(Eyes close)를 분리하여 결과를 확인하였는데 EO 보다 EC에서 더 낮은 예측 결과를 보였다. 이는 시각이 차단되면 중심을 잡기가 어려워 불안정하기 때문이다. 모델을 통해 COM 예측을 끝내 후 모델을 검증하기 위해 ANOVA와 사후분석을 진행하였다. ANOVA 진행결과 $F=19.1(p<0.05)$ 로 모델 간 유의미한 차이가 있다는 것을 확인하고 어떤 모델에서 차이가 있는지 확인하기 위해 사후분석을 진행한 결과 Bi-LSTM, CNN > RF라는

결과가 나왔다.

실험 데이터와 인공지능 모델에 대한 한계점은 분명히 존재한다. 하지만 저가의 장비로 압력 데이터를 획득하고 압력 데이터를 기반으로 인공지능 모델을 이용해 COM을 예측하는 본 연구가 COM 획득에 유용할 것으로 사료된다.

참 고 문 헌

- 1) A. L. Betker, T. “Estimation of 2-D Center of Mass Movement During Trunk Flexion - Extension Movements Using Body Accelerations.” IEEE Transactions on Neural Systems and Rehabilitation Engineering Volume 17, no. 6 (2009): 553-559
- 2) LATTANZI, Emanuele, et al. Standing balance assessment by measurement of body center of gravity using smartphones. IEEE Access, 2020, 8: 96438-96448.
- 3) Yi-Chung Pai. “Center of Mass Velocity-Position Predictions for Balance Control.” Journal of Biomechanics Volume 30, no. Issue 4 (1997): 347 - 354.
- 4) A. Choi, E. Park, T. H. Kim, G. J. Im and J. H. Mun. “A Novel Optimization-Based Convolution Neural Network to Estimate the Contribution of Sensory Inputs to Postural Stability During Quiet Standing.” IEEE Journal of Biomedical and Health Informatics Volume 26, no. 9 (2022): 4414 - 4425.
- 5) Sonobe, Motomichi, and Yoshio Inoue. 2023. "Center of Mass Estimation Using a Force Platform and Inertial Sensors for Balance Evaluation in Quiet Standing" Sensors 23, no. 10: 4933.

- 6) P. Dileep, D. Das and P. K. Bora. "Dense Layer Dropout Based CNN Architecture for Automatic Modulation Classification." National Conference on Communications (NCC), Kharagpur, India, 2020, 1 - 5.
- 7) Farah Shahid, Aneela Zameer, Muhammad Muneeb. "Predictions for COVID-19 with Deep Learning Models of LSTM, GRU and Bi-LSTM." Chaos, Solitons & Fractals Volume 140 (2020): 779 - 960.
- 8) "Full body modeling with Plug-in Gait," Vicon Nexus 2 Documentation, Vicon
- 9) Lee, Yechan, Yeongryeol Choi, Hyungtae Cho, and Junghwan Kim. "Prediction of Distillation Column Temperature Using Machine Learning and Data Preprocessing." Korean Chemical Engineering Research 59, no. 2 (May 1, 2021): 191 - 99
- 10) 최용욱, et al. 베이지안 최적화를 이용한 암상 분류 모델의 하이퍼 파라미터 탐색. 지구물리와 물리탐사, 2020, 23.3: 157-167.
- 11) KWAK, Jee-yoon, et al. BICF: Collaborative Filtering Based on Online Behavior Information. In: Proceedings of the Korea Information Processing Society Conference. Korea Information Processing Society, 2020. p. 401-404.
- 12) KIM, R. M.; KIM, K. M.; AHN, Johng-Hwa. Comparison between random forest and recurrent neural network for photovoltaic power forecasting. J Korean Soc Environ Eng, 2021, 43.5: 347-355.
- 13) PHAN, Huy, et al. Robust audio event recognition with 1-max pooling convolutional neural networks. arXiv preprint arXiv:1604.06338, 2016.
- 14) LEE, Gyeong-Hoon; JO, Jeil; PARK, Cheong Hee. Prediction of Jamming Techniques by Using LSTM. Journal of the Korea Institute of Military Science and Technology, 2019, 22.2: 278-286.
- 15) GHORBANI, Mohammad Ali, et al. Application of firefly algorithm-based support vector machines for prediction of field capacity and permanent wilting point. Soil and Tillage Research, 2017, 172: 32-38.
- 16) Youn, S. H., Sim, T., Choi, A., Song, J., Shin, K. Y., Lee, I. K., Heo, H. M., Lee, D., and Mun, J. H., 2015, "Multi-Class Biological Tissue Classification Based on a Multi-Classifer: Preliminary Study of an Automatic Output Power Control for Ultrasonic Surgical Units," Comput. Biol. Med., 61, pp. 92 - 100.